

CDCP - Classificador de Chamados Públicos

ETAPA DE PRÉ-PROCESSAMENTO DA BASE DE TREINAMENTO

1 – Eliminação de atributos irrelevantes

A base conta com 7 atributos: id, data_criacao, tipo_chamado, dias_problemas, risco_vida_humana, risco_vida_animal, bloqueio_via; e uma classe: urgencia.

Retirados os atributos id e data_criacao:

id -> Desnecessário para análise;

data_criacao -> Reflete data de criação do chamado, não tem relação com o atributo dias_problemas, e não deve ser considerado na análise, pois o chamado deve ser classificado no mesmo dia, não interferindo esse campo na classe urgencia;

Mantidos os campos:

dias_problemas -> O usuário informará quantos dias que fazem que o problema relatado no chamado existe, não necessariamente é no mesmo dia da abertura do chamado, pode ser antes; (Atributo contínuo)

risco_vida_humana -> Atributo descritivo, podendo ser Sim ou Não

risco_vida_animal -> Atributo descritivo, podendo ser Sim ou Não

bloqueio_via -> Atributo descritivo, podendo ser Sim ou Não

urgencia -> classe descritiva (URGENTE, ALTA, MEDIA, BAIXA)

2 – Tratamento de atributos com valores ausentes

Nessa base não foi encontrado nenhum atributo ausente ou nulo em nenhum registro/instancia.

3 – Tratamento de dados inconsistentes ou redundantes

Foram removidas um total de 3228 linhas redundantes ou inconsistentes, de 8154 linhas originais da base.

Como estatísticas principais da base, só foi possível calcular as estatísticas do atributo dias_problema, pois é o único numérico:

dias_problema	
count	4926.000000
mean	102.401340
std	70.082483
min	1.000000
25%	37.000000
50%	96.000000
75%	156.000000
max	256.000000

4 – Normalização dos atributos

Para esse caso só foi normalizado o atributo dias_problema:

Total de amostras: 4926

Primeira amostra da base antes da normalização: [51.0000].


Primeira amostra da base após normalização: [-0.7334].

Executada a normalização, levando a Média a 0 e o Desvio Padrão a 1.

dias_problema	
count	5411.000000
mean	0.000000
std	1.000000
min	-1.434756
25%	-0.938559
50%	-0.087934
75%	0.762690
max	2.180398

5 - Detecção de outliers

Para essa etapa foi efetuada a detecção de outliers para o atributo dias_problema somente:



Como Outliers não foram encontrados, não é possível verificar se são erros ou não, não sendo necessário remove-los.

Como não há mais de um atributo numérico, não é possível gerar um gráfico de dispersão. O gráfico de dispersão é utilizado para visualizar a relação entre dois ou mais atributos numéricos.


6 – Distribuição de Classes (urgencia)

URGENTE: 3484

ALTA: 741

MEDIA: 579

BAIXA: 122



Etapa de Extração Padrão da Base de Treinamento do PI

1 - Criar conjunto de validação de dados

Nessa etapa foram selecionados os dados para treinamento do modelo e os dados para a validação do treinamento desse modelo, ambos extraídos da mesma base de dados. Sendo para o treino 6911 registros e para a validação 1728 registros.

2 – Escolha dos algoritmos a serem treinados

Os algoritmos escolhidos para treinamento, avaliando qual se sairia melhor no cenário, foram:

Regressão Logística (LR)

Análise Linear Discriminante (LDA)

K-vizinhos mais próximos (KNN)

Árvores de Classificação (Decision Tree) e Regressão (CART)

Gaussian Naive Bayes (NB)

Support Vector Machines (SVM)

3 – Resultado da precisão dos algoritmos:

LR: 78,48%

LDA: 78,70%

KNN: 81,72%

CART: 82,57%

NB: 75,80%

SVM: 79,85%

4 – Especificação do treinamento e avaliação de cada algoritmo treinado

KNN – Treinamento

```
Acurácia Treino: 0.8690493416292866
Matriz de Confusão (Treino):
[[4426  183    8    0]
 [ 237  793  169    1]
 [   23  173  668   26]
 [    1   16   68  119]]
```

KNN – Validação

```
Acurácia Validação: 0.8130787037037037
Matriz de Confusão (Validação):
[[1081  70   4   0]
 [  85 159  56   0]
 [   7  69 140   6]
 [   0   5  21  25]]
```

LR – Treinamento

```
Acurácia Treino: 0.7846910722037331
Matriz de Confusão (Treino):
[[4476 137   4   0]
 [ 654 304 242   0]
 [ 115 133 642   0]
 [  18  17 168   1]]
```

LR – Validação

```
Acurácia Validação: 0.7824074074074074
Matriz de Confusão (Validação):
[[1126  28   1   0]
 [ 175  69  56   0]
 [  35  30 157   0]
 [   2   4  45   0]]
```

LDA – Treinamento

```
Acurácia Treino: 0.789755462306468
Matriz de Confusão (Treino):
[[4306 303   4   4]
 [ 467 486 236  11]
 [  58 182 603  47]
 [   1  30 110  63]]
```

LDA – Validação

```
Acurácia Validação: 0.7945601851851852
Matriz de Confusão (Validação):
[[1089  65   1   0]
 [ 120 123  55   2]
 [  20  41 149  12]
 [   0   6  33  12]]
```

CART – Treinamento

```
Acurácia Treino: 0.8755607003328028
Matriz de Confusão (Treino):
[[4448 158 11 0]
 [ 241 743 214 2]
 [ 7 139 719 25]
 [ 0 7 56 141]]
```

CART – Validação

```
Acurácia Validação: 0.8258101851851852
Matriz de Confusão (Validação):
[[1092 61 2 0]
 [ 77 156 66 1]
 [ 6 53 150 13]
 [ 0 1 21 29]]
```

NB – Treinamento

```
Acurácia Treino: 0.7799160758211546
Matriz de Confusão (Treino):
[[4454 154 7 2]
 [ 641 272 250 37]
 [ 100 99 531 160]
 [ 15 7 49 133]]
```

NB – Validação

```
Acurácia Validação: 0.7789351851851852
Matriz de Confusão (Validação):
[[1115 39 1 0]
 [ 173 62 55 10]
 [ 27 28 131 36]
 [ 1 2 10 38]]
```

SVM – Treinamento

```
Acurácia Treino: 0.8052380263348285
Matriz de Confusão (Treino):
[[4368 242 7 0]
 [ 465 468 266 1]
 [ 87 122 656 25]
 [ 18 6 107 73]]
```

SVM – Validação

```
Acurácia Validação: 0.8084490740740741
Matriz de Confusão (Validação):
[[1104  50   1   0]
 [ 119 121  60   0]
 [  23  36 156   7]
 [   2   1  32  16]]
```

5 – Algoritmo escolhido

Como modelo para o nosso projeto, foi escolhido o CART pois apresenta os melhores resultados de precisão em validação (82%). Após isso foi gerado o executável do mesmo e colocado na API do projeto.